

Предсказание цен акций на 30 дней по топ компаниям МОЕХ

Команда



Ступников

Дмитрий



Садоян

Давид



Савин

Владислав



Ключова

Ульяна


Описание и цель проекта

Данные: 2 датасета с ценами 19 компаний и новостям с [finam.ru](#)
за 5 лет

Бизнес-ценность: обоснованные инвестиционные решения,
автоматическая агрегированная обработка новостей и цен
вместе для управления портфелем

Цель


Разработать эффективную модель для краткосрочного
прогнозирования цен акций российского рынка (горизонт - 30
дней), объединяющую ценовые данные и анализ новостного
контекста



Если кто захочет заработать -
принимаем депозиты с комиссией
5% от прибыли
писать @Dmitriy_000

Ключевая гипотеза


Синергия ценовых данных,
технических индикаторов и
опережающего сигнала новостей




Более точные и **надёжные**
предсказания цен по сравнению с
расчётом лишь из цен и
индикаторов

Данные


Рыночные данные



Источник: moex.com




Тикеры: 19 публичных компаний
(верхушка тоех рейтинга)




Признаки:

- `open`, `close`, `high`, `low` — цены открытия, закрытия, дневной максимум и минимум
- `volume` — объём торгов
- `date` — торговый день
- `ticker` — идентификатор компании


Новостные данные



Источник: finam.ru




Признаки: `date`, `title`, `publication`




Задача: связать новости с конкретными компаниями и извлечь тональность


Обработка новостей




Бейзлайн




В качестве первой модели был выбран catboost




Результаты 1 дня: МАЕ = 0.017



Результаты 30 дня: МАЕ = 0.1574



Пока прогноз на более долгий срок уж слишком плохой из-за сложных временных зависимостей



На бейзлайне гипотеза себя не оправдала: новости не особо влияют



Модели


Feature engineering

88 признаков: ценовые данные, результаты новостного анализа, технические индикаторы и свечные паттерны


- Catboost
- Random Forest
- Ridge

1. Базовые ценовые признаки (5 штук):
open, high, low, close, volume
2. Признаки анализа тональности (6 штук):
sentiment score, sentiment label,
positive/negative/neutral prob, confidence
3. Технические индикаторы (11 штук):
SMA, EMA, RSI, MACD, ATR
4. Свечные паттерны (60 штук):
Технические паттерны - бинарные признаки
5. Временные признаки (6 штук):
month, weekday, month_sin, month_cos,
weekday_sin, weekday_cos


Новые успехи!




Сравнивается catboost, random forest и ridge




Результаты, особенно на долгосрок сильно улучшились




Новые фичи себя отлично показали, разница в более чем 2 раза




Random forest остаёт, а вот CatBoost и Ridge идут абсолютно вровень





Формально - мы ошибаемся лишь на 6% в цене через 30 дней, что неплохой результат




Интерпретация




Catboost




Ridge




Влияние новостей




Итого: новости не влияют на прогноз цены с 1 до 30 дней




Из-за ликвидных активов




Из-за концентрации российского рынка на торговле “На новостях”



Такая обработка новостей не учитывает их накопительный эффект и “сюжеты”



Большая часть рынка торгует по индикаторам =)



Выводы и ограничения

Основные выводы

Влияние новостей

- Интеграция сентимент-анализа не оказала влияния

Технические индикаторы спасают catboost

- Из-за невозможности анализа глубоких временных паттернов, индикаторы существенно улучшают работу модели

Линейные модели тоже могут пободаться с ансамблями

- При этом ridge гораздо более интерпретируем и быстр

Гипотеза опровергнута

Такой вид анализа новостей не помогает предсказывать цены, что говорит о достаточно эффективном рынке на ликвидных акциях. Новости могут быть применимы только в очень краткосрочной торговле (10-15 минут)

Ограничения текущего и что можно сделать еще

Макроэкономические и корпоративные факторы

- Модели не учитывают общую экономическую ситуацию в стране и ситуацию в компании

Качество сентимент-анализа

- Также результаты зависят от возможностей NLP и ограниченности одного источника новостей

Возможные нововведения

Улучшенная обработка новостей со всех источников и сбор макроэкономических факторов + подсчёт мультипликаторов